

# Curs 11

Cristian Niculescu

## 1 Actualizare Bayesiană: predicție probabilistică

### 1.1 Scopul învățării

Să poată să utilizeze legea probabilității totale pentru a calcula probabilitățile predictive a priori și a posteriori.

### 1.2 Introducere

Am văzut actualizarea probabilității ipotezelor bazată pe date. Putem de asemenea folosi datele pentru a actualiza probabilitatea fiecărui rezultat posibil al unui experiment viitor.

#### 1.2.1 Predicție probabilistică; cuvinte de probabilitate estimativă (WEP)

Moduri de predicție:

Predicție: "Mâine va ploua."

Predicție folosind cuvinte de probabilitate estimativă (WEP): "Este probabil să plouă mâine."

Predicție probabilistică: "Mâine va ploua cu probabilitatea de 60% (și nu plouă cu probabilitatea de 40%)."

Fiecare tip de formulare este adecvat în diverse momente. Puteți vedea [http://en.wikipedia.org/wiki/Words\\_of\\_Estimative\\_Probability](http://en.wikipedia.org/wiki/Words_of_Estimative_Probability) pentru o discuție despre utilizarea adecvată a cuvintelor de probabilitate estimativă. Articolul conține de asemenea o listă de *cuvinte nevăstuică* (*weasel words*) ca "ar putea (might)", "nu poate exclude (cannot rule out)", "este de conceput (it's conceivable)" care ar trebui evitate deoarece aproape sigur produc confuzie.

Sunt multe locuri unde vrem să facem o predicție probabilistică. Exemple:  
Rezultate ale tratamentului medical

Prognoza meteo  
 Schimbarea climei  
 Pariuri sportive  
 Alegeri

...

Acestea sunt toate situații unde există incertitudine despre rezultat și am vrea o descriere cât mai precisă posibil a ce se poate întâmpla.

### 1.3 Probabilități predictive

Predicția probabilistică înseamnă atribuirea unei probabilități fiecărui rezultat posibil al unui experiment.

Reconsiderăm exemplul cu monedele: sunt 3 tipuri de monede care sunt de nedistins în afară de probabilitățile lor de avers la aruncare.

Monedele de tip  $A$  sunt corecte, cu probabilitatea aversului 0.5.


Monedele de tip  $B$  au probabilitatea aversului 0.6.

Monedele de tip  $C$  au probabilitatea aversului 0.9.

Avem un sertar cu 4 monede: 2 de tip  $A$ , una de tip  $B$  și una de tip  $C$ . Alegem o monedă din sertar. Fie  $A$  evenimentul "moneda aleasă este de tipul  $A$ ". Analog pentru  $B$  și  $C$ .

#### 1.3.1 Probabilități predictive a priori

Înainte de a colecta datele, calculăm probabilitatea ca moneda aleasă de noi să dea avers (sau revers) dacă o aruncăm. Fie  $D_H$  evenimentul "avers" și  $D_T$  evenimentul "revers". Putem folosi [legea probabilității totale](#) pentru a determina probabilitățile acestor evenimente. Desenând un arbore sau calculând cu formula, obținem ("Coin type" = "tipul monedei", "Flip result" = "rezultatul aruncării"):



$$\begin{aligned}
P(D_H) &= P(D_H|A)P(A) + P(D_H|B)P(B) + P(D_H|C)P(C) \\
&= 0.5 \cdot 0.5 + 0.6 \cdot 0.25 + 0.9 \cdot 0.25 = 0.625 \\
P(D_T) &= P(D_T|A)P(A) + P(D_T|B)P(B) + P(D_T|C)P(C) \\
&= 0.5 \cdot 0.5 + 0.4 \cdot 0.25 + 0.1 \cdot 0.25 = 0.375.
\end{aligned}$$


**Definiție:** Aceste probabilități dau o predicție (probabilistică) a ce se va întâmpla dacă moneda este aruncată. Deoarece ele sunt calculate înainte de a colecta orice dată, ele se numesc **probabilități predictive a priori**.

### 1.3.2 Probabilități predictive a posteriori

Presupunem că aruncăm moneda o dată și obținem avers. Acum avem datele  $D$ , pe care le putem folosi pentru a actualiza probabilitățile a priori ale ipotezelor noastre la probabilități a posteriori. Folosim un tabel Bayes pentru a facilita acest calcul:

hypothesis	prior	likelihood	Bayes	
			numerator	posterior
$H$	$P(H)$	$P(D H)$	$P(D H)P(H)$	$P(H D)$
$A$	0.5	0.5	0.25	0.4
$B$	0.25	0.6	0.15	0.24
$C$	0.25	0.9	0.225	0.36
total	1		0.625	1

Dacă am aruncat moneda o dată și am obținut avers, putem calcula probabilitatea că moneda aleasă de noi va da avers (sau revers) dacă o aruncăm a 2-a oară. Procedăm ca mai sus, dar folosind probabilitățile a posteriori  $P(A|D)$ ,  $P(B|D)$ ,  $P(C|D)$  în locul probabilităților a priori  $P(A)$ ,  $P(B)$ ,  $P(C)$ .



$$\begin{aligned}
P(D_H|D) &= P(D_H|A)P(A|D) + P(D_H|B)P(B|D) + P(D_H|C)P(C|D) \\
&= 0.5 \cdot 0.4 + 0.6 \cdot 0.24 + 0.9 \cdot 0.36 = 0.668 \\
P(D_T|D) &= P(D_T|A)P(A|D) + P(D_T|B)P(B|D) + P(D_T|C)P(C|D) \\
&= 0.5 \cdot 0.4 + 0.4 \cdot 0.24 + 0.1 \cdot 0.36 = 0.332.
\end{aligned}$$

**Definiție:** Aceste probabilități dau o predicție (probabilistică) a ceea ce se va întâmpla dacă moneda este aruncată iar. Deoarece sunt calculate după colectarea datelor și actualizarea a priori la a posteriori, ele sunt numite [probabilități predictive a posteriori](#).

Observăm că aversul la prima aruncare crește probabilitatea aversului la a 2-a aruncare.

### 1.3.3 Recapitulare

Fiecare ipoteză dă o probabilitate diferită a aversului, deci probabilitatea totală a aversului este o medie ponderată. Pentru probabilitatea predictivă a priori a aversului, ponderile sunt date de probabilitățile a priori ale ipotezelor. Pentru probabilitatea predictivă a posteriori a aversului, ponderile sunt date de probabilitățile a posteriori ale ipotezelor.

**Rețineți:** Probabilitățile a priori și a posteriori sunt pentru ipoteze. Probabilitățile predictive a priori și a posteriori sunt pentru date. Ultimele [prezic](#) datele viitoare.

## 2 Actualizare Bayesiană: șanse

### 2.1 Scopurile învățării

1. Să poată converti șansele în probabilitate și invers.
2. Să poată actualiza șansele a priori în șanse a posteriori folosind factori Bayes.
3. Să înțeleagă cum factorii Bayes măsoară gradul în care datele dau dovezi pentru sau împotriva ipotezelor.

### 2.2 Șanse

Când comparăm 2 evenimente, putem formula afirmațiile probabilistice în termeni de șanse.

**Definiție.** [Șansele](#) unui eveniment  $E$  versus evenimentul  $E'$  sunt raportul probabilităților lor  $P(E)/P(E')$ . Dacă nu se specifică evenimentul  $E'$ , al

2-lea eveniment este presupus a fi evenimentul complementar  $E^c$ . Astfel, șansele lui  $E$  sunt:

$$O(E) = \frac{P(E)}{P(E^c)}.$$

De exemplu,  $O(\text{ploaie}) = 2$  înseamnă că probabilitatea de a ploua este de 2 ori probabilitatea de a nu ploua ( $2/3$  versus  $1/3$ ). Putem spune că "șansele de ploaie sunt 2 la 1".

**Exemplu.** Pentru o monedă corectă,  $O(\text{avers}) = \frac{1/2}{1/2} = 1$ . Putem spune că șansele aversului sunt 1 la 1 sau 50-50.

**Exemplu.** Pentru un zar standard, șansele de a da 4 sunt  $\frac{1/6}{5/6} = \frac{1}{5}$ . Putem spune că șansele sunt "1 la 5 pentru" sau "5 la 1 împotriva" a da un 4.

**Exemplu.** Probabilitatea unei perechi într-o mână de poker de 5 cărți este 0.42257. Astfel, șansele unei perechi sunt  $0.42257/(1 - 0.42257) = 0.73181$ .

**Formule de conversie:** Dacă  $P(E) = p$ , atunci  $O(E) = \frac{p}{1-p}$ . Dacă  $O(E) = q$ , atunci  $P(E) = \frac{q}{1+q}$ .

Observații:

1. A 2-a formulă provine din rezolvarea ecuației în  $p$   
 $q = p/(1 - p)$ .
2. Probabilitățile sunt între 0 și 1, în timp ce șansele sunt între 0 și  $\infty$ .
3. Proprietatea  $P(E^c) = 1 - P(E)$  devine  $O(E^c) = 1/O(E)$ .

**Exemplu.** Fie  $F$  evenimentul că o mână de poker să fie ful (3 cărți de un rang și alte 2 cărți de un alt rang). Atunci  $P(F) = 0.0014521$  deci  $O(F) = 0.0014521/(1 - 0.0014521) = 0.0014542$ .

Șansele de a nu avea ful sunt

$$O(F^c) = (1 - 0.0014521)/0.0014521 = 687.6578 = 1/O(F).$$

4. Dacă  $P(E)$  sau  $O(E)$  este mic, atunci  $O(E) \approx P(E)$ . Aceasta rezultă din formulele de conversie.

**Exemplu.** La exemplul din poker, unde  $F$  = "ful", am văzut că  $P(F)$  și  $O(F)$  diferă abia la a 6-a zecimală.

## 2.3 Actualizarea șanselor

### 2.3.1 Introducere

În actualizarea Bayesiană, am utilizat verosimilitatea datelor pentru a actualiza probabilitățile a priori ale ipotezelor la probabilități a posteriori. În limbaj de șanse, vom actualiza șansele a priori la șanse a posteriori. Datele dau dovezi pentru sau împotriva unei ipoteze dacă șansele ei a posteriori sunt mai mari sau mai mici decât șansele ei a priori.

### 2.3.2 Exemplu: sindromul Marfan

Sindromul Marfan este o boală genetică a țesutului conjunctiv care apare la 1 din 15000 de oameni. Principalele caracteristici oculare ale sindromului Marfan includ ectopia de cristalin bilaterală, miopie și detașarea retinei. Aproximativ 70% din oamenii cu sindrom Marfan au cel puțin una din aceste caracteristici oculare, în timp ce doar 7% din oamenii fără sindrom Marfan au. (Nu garantăm acuratețea acestor numere.)

Dacă o persoană are cel puțin una din aceste caracteristici oculare, care sunt șansele să aibă sindromul Marfan?

**Răspuns:** Aceasta este o problemă standard de actualizare Bayesiană. Ipotezele noastre sunt:

$M$  = "persoana are sindromul Marfan",

$M^c$  = "persoana nu are sindromul Marfan".

Datele sunt:

$F$  = "persoana are cel puțin o caracteristică oculară".

Știm probabilitatea a priori a lui  $M$  și verosimilitățile lui  $F$  dat fiind  $M$  sau  $M^c$ :

$$P(M) = 1/15000, P(F|M) = 0.7, P(F|M^c) = 0.07.$$

Putem calcula probabilitățile a posteriori folosind un tabel:

hypothesis	prior	likelihood	Bayes	
			numerator	posterior
$H$	$P(H)$	$P(F H)$	$P(F H)P(H)$	$P(H F)$
$M$	0.000067	0.7	0.0000467	0.00066
$M^c$	0.999933	0.07	0.069995	0.99933
total	1		0.07004	1

Șansele a priori sunt:

$$O(M) = \frac{P(M)}{P(M^c)} = \frac{1/15000}{14999/15000} = \frac{1}{14999} \approx 0.000067.$$

Șansele a posteriori sunt date de raportul probabilităților a posteriori sau al numărărilor Bayes, deoarece factorul normalizator este același la numărător și la numitor.

$$O(M|F) = \frac{P(M|F)}{P(M^c|F)} = \frac{P(F|M)P(M)}{P(F|M^c)P(M^c)} = 0.000667.$$

Șansele a posteriori sunt de 10 ori mai mari decât șansele a priori. În acest sens, a avea o caracteristică oculară este o dovadă puternică în favoarea

ipotezei  $M$ . Totuși, deoarece șansele a priori sunt atât de mici, este încă foarte puțin probabil ca persoana să aibă sindromul Marfan.

## 2.4 Factorii Bayes și puterea dovezii

Factorul 10 din exemplul precedent se numește factor Bayes.

**Definiție:** Pentru ipoteza  $H$  și datele  $D$ , **factorul Bayes** este raportul verosimilităților:

$$\text{factorul Bayes} = \frac{P(D|H)}{P(D|H^c)}.$$

Să vedem exact unde factorul Bayes apare în actualizarea șanselor. Avem

$$\begin{aligned} O(H|D) &= \frac{P(H|D)}{P(H^c|D)} \\ &= \frac{P(D|H)P(H)}{P(D|H^c)P(H^c)} \\ &= \frac{P(D|H)}{P(D|H^c)} \cdot \frac{P(H)}{P(H^c)} \\ &= \frac{P(D|H)}{P(D|H^c)} \cdot O(H). \end{aligned}$$

$$\text{șansele a posteriori} = \text{factorul Bayes} \times \text{șansele a priori}.$$

Din această formulă vedem că factorul Bayes ( $BF$ ) ne spune dacă datele dau dovezi pentru sau împotriva ipotezei.

Dacă  $BF > 1$ , atunci șansele a posteriori sunt mai mari decât șansele a priori. Astfel, datele dau dovezi pentru ipoteză.

Dacă  $BF < 1$ , atunci șansele a posteriori sunt mai mici decât șansele a priori. Astfel, datele dau dovezi împotriva ipotezei.

Dacă  $BF = 1$ , atunci șansele a priori și a posteriori sunt egale. Astfel, datele nu dau nicio dovadă pentru sau împotriva ipotezei.

Următorul exemplu este din cartea *Information Theory, Inference, and Learning Algorithms* de David J. C. Mackay, care spune cu privire la probele dintr-un proces:

”În opinia mea, sarcina unui juriu ar trebui în general să fie a înmulți împreună rapoarte de verosimilitate evaluate cu grijă de la fiecare parte independentă de dovadă admisibilă cu o probabilitate a priori motivată la fel de grijuliu. Acest punct de vedere este împărtășit de mulți statisticieni, dar învățații judecători de apel britanici nu au fost de acord recent și în realitate au răsturnat verdictul unui proces deoarece jurații fuseseră învățați să utilizeze teorema lui Bayes pentru a trata dovezi ADN complicate.”

**Exemplul 1.** 2 oameni au lăsat urme de sânge la locul unei crime. Un suspect, Oliver, are grupa de sânge "0". Grupele de sânge ale celor 2 urme sunt "0" (o grupă obișnuită în populația locală, având frecvența 60%) și "AB" (o grupă rară, cu frecvența 1%). Dau aceste date (grupele "0" și "AB" găsite la locul crimei) dovezi în favoarea propoziției că "Oliver a fost una dintre cele 2 persoane prezente la locul crimei"?

**Răspuns:** Sunt 2 ipoteze:

$S$  = "Oliver și o altă persoană necunoscută au fost la locul crimei";

$S^c$  = "2 persoane necunoscute au fost la locul crimei".

Datele sunt:

$D$  = "grupele de sânge "0" și "AB" au fost găsite".

Factorul Bayes pentru prezența lui Oliver este  $BF_{\text{Oliver}} = \frac{P(D|S)}{P(D|S^c)}$ . Calculăm numărătorul și numitorul separat.

Datele spun că ambele grupe de sânge "0" și "AB" au fost aflate la locul crimei. Dacă Oliver a fost la locul crimei, grupa "0" ar fi acolo. Deci,  $P(D|S)$  este probabilitatea că cealaltă persoană avea grupa "AB". Ni s-a spus că aceasta este 0.01, deci  $P(D|S) = 0.01$ .

Dacă Oliver nu a fost la locul crimei, atunci au fost 2 persoane aleatoare, una cu grupa "0" și una cu grupa "AB". Probabilitatea acestui fapt este  $2 \cdot 0.6 \cdot 0.01$ . Factorul 2 este deoarece sunt 2 moduri în care se poate întâmpla asta - prima persoană are grupa 0 și a 2-a grupa AB sau viceversa. (Am presupus că grupele de sânge ale celor 2 persoane sunt independente. Aceasta nu este exact adevărat, dar pentru o populație suficient de mare este destul de aproape de adevăr. Fie  $N_0$ , numărul de oameni cu grupa 0,  $N_{AB}$ , numărul de oameni cu grupa AB și  $N$ , mărimea populației. Probabilitatea exactă este  $\frac{(N_0-1) \cdot N_{AB}}{C_{N-1}^2} = \frac{2 \cdot (N_0-1) \cdot N_{AB}}{(N-1)(N-2)} = 2 \cdot \frac{0.6N-1}{N-1} \cdot \frac{0.01N}{N-2} \xrightarrow{N \rightarrow \infty} 2 \cdot 0.6 \cdot 0.01$ . Aceasta arată că pentru  $N$  suficient de mare, probabilitatea este aproximativ  $2 \cdot 0.6 \cdot 0.01$ .) Factorul Bayes pentru prezența lui Oliver la locul crimei este

$$BF_{\text{Oliver}} = \frac{P(D|S)}{P(D|S^c)} \approx \frac{0.01}{2 \cdot 0.6 \cdot 0.01} = 0.8(3).$$

Deoarece  $BF_{\text{Oliver}} < 1$ , datele dau dovezi (slabe) împotriva prezenței lui Oliver la locul crimei.

**Exemplul 2.** Un alt suspect, Alberto, are grupa de sânge AB. Dau aceleași date dovezi în favoarea propoziției că Alberto a fost una din cele 2 persoane prezente la locul crimei?

**Răspuns:** Refolosind notațiile de mai sus cu Alberto în locul lui Oliver, avem:

$$BF_{\text{Alberto}} = \frac{P(D|S)}{P(D|S^c)} \approx \frac{0.6}{2 \cdot 0.6 \cdot 0.01} = 50.$$



Deoarece  $BF_{\text{Alberto}} \gg 1$ , datele dau o dovadă puternică în favoarea prezenței lui Alberto la locul crimei.

Observații:

1. În ambele exemple, am calculat doar factorul Bayes, nu șansele a posteriori. Pentru a le calcula pe ultimele, am avea nevoie să știm șansele a priori pentru prezența lui Oliver (sau Alberto) la locul crimei, pe baza altor dovezi.
2. Dacă 50% din populație ar fi avut grupa 0 de sânge în loc de 60%, atunci factorul Bayes al lui Oliver ar fi fost 1 (nici pentru, nici împotriva). Mai general, punctul de echilibru pentru dovezile cu grupe de sânge este când proporția grupei de sânge a suspectului din populația generală egalează proporția grupei de sânge a suspectului dintre cele aflate la locul crimei.

### 2.4.1 Reactualizare

Presupunem că adunăm datele în 2 etape, întâi  $D_1$ , apoi  $D_2$ . A posteriori finale pot fi calculate toate o dată sau în 2 etape, unde întâi actualizăm a priori folosind verosimilitățile pentru  $D_1$  și apoi actualizăm a posteriori rezultate după prima actualizare folosind verosimilitățile pentru  $D_2$ . Ultima abordare merge ori de câte ori verosimilitățile se înmulțesc:

$$P(D_1, D_2|H) = P(D_1|H)P(D_2|H).$$

Deoarece verosimilitățile sunt condiționate de ipoteze, spunem că  $D_1$  și  $D_2$  sunt **condiționat independente** dacă relația de mai sus are loc pentru orice ipoteză  $H$ .

**Exemplu.** Sunt 5 zaruri într-un sertar, cu 4, 6, 8, 12 și 20 de fețe (acestea sunt ipotezele). Luăm aleator un zar și-l aruncăm de 2 ori, obținând întâi 7, apoi 11. Sunt aceste rezultate condiționat independente? Dar independente?

**Răspuns.** Rezultatele sunt condiționat independente. De exemplu, pentru ipoteza zarului cu 8 fețe avem:

$$\begin{aligned}P(7 \text{ la aruncarea } 1 | \text{zar cu } 8 \text{ fețe}) &= 1/8, \\P(11 \text{ la aruncarea } 2 | \text{zar cu } 8 \text{ fețe}) &= 0, \\P(7 \text{ la aruncarea } 1, 11 \text{ la aruncarea } 2 | \text{zar cu } 8 \text{ fețe}) &= 0.\end{aligned}$$

Pentru ipoteza zarului cu 20 de fețe avem:

$$\begin{aligned}P(7 \text{ la aruncarea } 1 | \text{zar cu } 20 \text{ fețe}) &= 1/20, \\P(11 \text{ la aruncarea } 2 | \text{zar cu } 20 \text{ fețe}) &= 1/20, \\P(7 \text{ la aruncarea } 1, 11 \text{ la aruncarea } 2 | \text{zar cu } 20 \text{ fețe}) &= (1/20)^2.\end{aligned}$$

Totuși, rezultatele nu sunt independente. Adică:

$$P(7 \text{ la aruncarea 1}, 11 \text{ la aruncarea 2}) \neq P(7 \text{ la aruncarea 1})P(11 \text{ la aruncarea 2}).$$

Intuitiv, aceasta este deoarece 7 la aruncarea 1 ne permite să eliminăm zarurile cu 4 și 6 fețe, făcând un 11 la aruncarea 2 mai probabil. Ne verificăm intuiția calculând ambii membri. La membrul drept avem:

$$\begin{aligned} P(7 \text{ la aruncarea 1}) &= \frac{1}{5} \cdot \frac{1}{8} + \frac{1}{5} \cdot \frac{1}{12} + \frac{1}{5} \cdot \frac{1}{20} = \frac{31}{600}, \\ P(11 \text{ la aruncarea 2}) &= \frac{1}{5} \cdot \frac{1}{12} + \frac{1}{5} \cdot \frac{1}{20} = \frac{2}{75}. \end{aligned}$$

Deci membrul drept este  $\frac{31}{600} \cdot \frac{2}{75} = 0.0013(7)$ .

Membrul stâng este:

$$\begin{aligned} &P(7 \text{ la aruncarea 1}, 11 \text{ la aruncarea 2}) \\ &= P(11 \text{ la aruncarea 2} | 7 \text{ la aruncarea 1}) \cdot P(7 \text{ la aruncarea 1}) \\ &= \left( \frac{10}{31} \cdot \frac{1}{12} + \frac{6}{31} \cdot \frac{1}{20} \right) \cdot \frac{31}{600} \\ &= \frac{17}{9000} = 0.001(8). \end{aligned}$$

Aici  $\frac{10}{31}$  și  $\frac{6}{31}$  sunt probabilitățile a posteriori ale zarurilor cu 12 și cu 20 de fețe dat fiind un 7 la aruncarea 1 (se pot calcula cu un tabel de actualizare Bayesiană).

Concluzionăm că, fără condiționarea de ipoteze, aruncările nu sunt independente.

Întorcându-ne la schema generală, dacă  $D_1$  și  $D_2$  sunt condiționat independente pentru  $H$  și  $H^c$ , atunci are sens să considerăm fiecare factor Bayes independent:

$$BF_i = \frac{P(D_i|H)}{P(D_i|H^c)}, i = 1, 2.$$

Șansele a priori ale lui  $H$  sunt  $O(H)$ . Șansele a posteriori după  $D_1$  sunt

$$O(H|D_1) = BF_1 \cdot O(H).$$

Șansele a posteriori după  $D_1$  și  $D_2$  sunt

$$\begin{aligned} O(H|D_1, D_2) &= BF_2 \cdot O(H|D_1) \\ &= BF_2 \cdot BF_1 \cdot O(H). \end{aligned}$$

Actualizarea șanselor cu date noi, condiționat independente de cele vechi, se face prin înmulțirea șanselor a posteriori curente cu factorul Bayes al noilor

date.

### Exemplul 3. Alte simptome ale sindromului Marfan

Reamintim din exemplul de mai devreme că factorul Bayes pentru cel puțin o caracteristică oculară ( $F$ ) este

$$BF_F = \frac{P(F|M)}{P(F|M^c)} = \frac{0.7}{0.07} = 10.$$

Semnul închieturii mâinii ( $W$ ) este capacitatea de a înfășura o mână în jurul celeilalte închieturi a mâinii astfel încât unghia degetului mic să poată fi acoperită de degetul mare. Presupunem că 10% din populație are semnul închieturii mâinii, în timp ce 90% din oamenii cu sindromul Marfan îl au. De aceea, factorul Bayes pentru semnul închieturii mâinii este

$$BF_W = \frac{P(W|M)}{P(W|M^c)} = \frac{0.9}{0.1} = 9.$$

Presupunem că  $F$  și  $W$  sunt simptome condiționat independente. Adică, printre oamenii cu sindromul Marfan, caracteristicile oculare și semnul închieturii mâinii sunt independente și printre oamenii fără sindromul Marfan, caracteristicile oculare și semnul închieturii mâinii sunt independente. Cu această presupunere, șansele a posteriori ale sindromului Marfan pentru cineva care are atât caracteristicile oculare cât și semnul închieturii mâinii sunt

$$O(M|F, W) = BF_W \cdot BF_F \cdot O(M) = 9 \cdot 10 \cdot \frac{1}{14999} \approx \frac{6}{1000}.$$

Putem converti șansele posterioare în probabilitate, dar, deoarece șansele sunt atât de mici, rezultatul este aproape același:

$$P(M|F, W) \approx \frac{6}{1000 + 6} \approx 0.596\%.$$

Așadar, caracteristicile oculare și semnul închieturii sunt ambele dovezi puternice în favoarea ipotezei  $M$  și, luate împreună, sunt dovezi foarte puternice. Din nou, deoarece șansele a priori sunt atât de mici, este încă improbabil că persoana are sindromul Marfan, dar în această situație merită să fie făcute alte teste date fiind consecințele potențial fatale ale bolii (ca anevrismul aortic sau disecția aortică).

Observăm de asemenea că, dacă o persoană are exact unul din cele 2 simptome, atunci produsul factorilor Bayes este aproape de 1 (9/10 sau 10/9). Astfel, cele 2 părți ale datelor se anulează una pe alta în ce privește dovezile pe care le dau pentru sindromul Marfan.

## 2.5 Log șanse

În practică, este adesea convenabil a lucra cu logaritmi naturali ai șanselor în locul șanselor. Destul de firesc, aceștia sunt numiți **log șanse**. Formula de actualizare Bayesiană

$$O(H|D_1, D_2) = BF_2 \cdot BF_1 \cdot O(H)$$

devine

$$\ln(O(H|D_1, D_2)) = \ln(BF_2) + \ln(BF_1) + \ln(O(H)).$$

Putem interpreta formula de mai sus pentru log șansele a posteriori ca suma log șanselor a priori cu toate dovezile  $\ln(BF_i)$  furnizate de date. Luând logaritmi, dovezile pentru  $(BF_i > 1)$  sunt pozitive și dovezile împotriva  $(BF_i < 1)$  sunt negative. Log șansele joacă de asemenea un rol central în regresia logistică, un model statistic legat de regresia liniară.